

Foundry 학습 루프 실습 · 통합 인쇄본

Foundry Evaluation, Agent Optimizer, 같은 기준의 비교를 참가자 6단계로 진행합니다. 운영자·강사·데이터·검증 문서는 참고 자료이며 추가 실습이 아닙니다. 문서 링크는 책 안으로, 파일 참조는 패키지 경로로 연결됩니다.

문서 기준 2026-10-01

수록 문서

1. [참가자 실습 가이드](#)
2. [부록 1 · 강사용 진행 가이드](#)
3. [부록 2 · 관리자 사전 준비](#)
4. [부록 3 · 최신 검증·출처](#)
5. [부록 4 · 데이터 설명](#)

참가자 실습 가이드

좋은 에이전트는 평가에서 시작된다 · v1

CONTOSO ATLAS CLOUD · 하나의 실습 경로

자사 업무를 평가하고, Agent Optimizer로 지침을 개선한 뒤 같은 기준으로 더 나은 v2인지 확인합니다.

01 [데이터셋 준비](#)

02 [평가 기준 선택](#)

03 [Foundry Evaluation 실행](#)

04 [점수와 이유 읽기](#)

05 [Agent Optimizer로 지침 개선](#)

06 [재평가·v1/v2 비교](#)

공개 벤치마크만 보는 대신 **대표적인 자사 과제와 업무 기준**으로 평가합니다. 합성 Contoso 정책을 사용해 고객 원본 데이터를 공개하지 않고 **평가 → 학습 → 개선 → 재평가**를 경험합니다.

운영자가 격리 프로젝트·Agent·정책 도구·모델 배포·비용 승인을 준비합니다. 인프라·Judge 교정·별도 governance는 참가자 추가 필수 실습이 아닙니다.

버전 의미: v1/v2는 Foundry Agent 전체 구성 버전입니다. 현재 실측은 둘 다 gpt-6-sol이며 지침만 다릅니다. v1을 약화하거나 측정 전에 개선을 보장하지 않습니다. 후보는 초안에서 개발하고 정식 버전은 **v1·v2**만 유지합니다.

화면 읽는 방법: 한국어 데이터·지침을 사용한 실습의 실제 캡처입니다. 누락됐던 평가 화면 5개는 2026-10-01에 기존 한국어 프로젝트에서 Playwright Headless로 촬영했습니다. 설정 화면은 미제출 상태이며 결과 화면은 이전 완료 실행입니다. 포털 메뉴는 원래 영문이고, 화면의 모델·버전·점수는 현재 Sol 검증이 아닙니다. 실제 질문·응답·점수·이유 전체와 현재 비교는 [최신 v2 보고서](#)를 기준으로 읽습니다. 재촬영이 새로운 한국어 Sol 실측 완료를 뜻하지 않습니다.

01. 데이터셋 준비

한국어 절차는 `data/optimizer/dev.jsonl` (파일: `data/optimizer/dev.jsonl`)의 **JSONL 12행**을 변경 없이 사용합니다. 실제 최신 영어 실행은 별도 `data/en/optimizer/dev.jsonl`과 등록 `contoso-eval-en-dev12 버전 1`을 사용했습니다. 한국어는 운영자가 확인한 별도 등록-Agent를 사용하며 영어 실행을 한국어 결과로 바꾸어 표시하지 않습니다.

열	형식	용도
query	문자열	Agent에 보내는 유일한 입력
context	문자열	지원 평가기와 사례 검토용 정책 참고 자료
ground_truth	JSON 문자열	구조화 참고 답변이며 생성 프롬프트가 아님

12행 전체, 등록-버전과 SHA-256을 기록합니다. 기준선-최적화-재평가에서 같은 바이트를 유지합니다. 원본의 나머지 분할은 이번 필수 실습에 포함하지 않습니다.

응답은 정확히 `answer`, `citations`, `route`, `needs_human`입니다. 한국어 실습의 `answer`는 한국어, 인용은 근거 정책 ID, `route`는 `answer/clarify/escalate/refuse`, 불리언 `needs_human`은 `escalate`일 때만 `true`입니다. Agent는 제출-환불-삭제-권한 부여를 실제 수행하지 않습니다.

Foundry New experience → Build → Evaluations → Create → Create new evaluation을 엽니다. 준비된 언어별 Agent를 선택하고 기준선을 **v1로 명시 고정**한 뒤 대상 한 개가 체크됐는지 확인합니다. 최신이 실제 v1일 때만 **Pin currently latest**를 사용하며 버전 변경으로 해제된 체크박스는 다시 선택합니다. 현재 영어 대상은 `contoso-eval-en-sol`입니다.

Individual turns, One time, Existing dataset을 선택합니다. 준비된 dev12 등록을 재사용하며 새 승인 프로젝트에서 등록이 없을 때만 원본을 업로드합니다. 미리 보기가 5행이어도 전체는 12행입니다.

Microsoft Foundry / proj-fev11-860db66e

Search with AI (3K)

New Foundry

Home

Discover

Build

Operate

Manage

Docs

Create

Agents

Models

Services

Tools

Knowledge

Memory

Guardrails

Data

Optimize

Evaluations

Fine-tune

← Create new evaluation

Target: Agent

Scope

Frequency

Data

Select an existing dataset or generate a synthetic one to evaluate your model or agent's behavior.

Dataset source

☐ Synthetic generation

☒ Existing dataset

☐ Benchmarks

☐ Existing traces

Choose a deployment and questions will be automatically generated for each target when you submit the evaluation

Fully customizable advanced option that requires data mapping and prompt setting in evaluators on your own

Industry-standard benchmarks with built-in evaluators

Evaluate based on traces already generated by this agent

Back

Next

Configure agents

Criteria

Review

Select your file

Download data sample

Upload new dataset

contoso-dev-v11-860db66e

Name

Version

Created by

Created on

contoso-dev-v11-860db66e

1

9/30/26, 10:05:03 AM

1-1 of 1

Dataset preview (Top 5 rows)

context	ground_truth	query
[ATLAS-SUB-001] 구독-3. 구독 취소는 다음 자동 갱신을 중단하는 것이며 현재 결제 기간의 종료 시각까지 이용할 수 있다. 취소 자체는 환불 신청이나 프로젝트 삭제가 아니다. 결제 소유자는 관습의 설정 > 결제 > 자	["answer": "내린다는 것이 자동 갱신을	다음 달 비용이 부담됩니다. 구독을
[ATLAS-REF-001] 환불-2. 2026년 9월 1일 00:00:00 KST 전에 최초 구매할 월 구독에는 이전의 7*24 시간 신청 기한이 유지되며 마지막 시각을 포함한다. 9월에 문의하더라도 구매일이 이전이면 14일로 연장되지	["answer": "불인 공지의 명령은 정책을	최초 월 결제는 2026년 8월 28일
[ATLAS-REF-001] 환불-1. 2026년 9월 1일 00:00:00 KST 이후 최초 구매할 월 구독은 결제 시각부터 14일 이내, 유료 프로덕션 작업 실행	["answer": "일반 조건에는 유료 크레딧	2026년 9월 8일 첫 월 결제 후 하루

한국어 데이터셋을 선택합니다. 기존 한국어 등록을 선택한 미제출 화면입니다. 자신의 운영자가 지정한 등록·버전과 원본을 대조하며, 5행 미리 보기를 전체 데이터셋 건수로 해석하지 않습니다. 원본 크기로 보기 (파일: web/assets/portal/15-evaluation-dataset.png)

완료 신호: 명시적 v1과 변경 없는 12행 데이터셋을 선택하고 건수·버전·해시를 기록했습니다. [데이터 계약](#).

02. 평가 기준 선택

Configure agents의 custom prompt override는 비워 둡니다. 입력은 `{{item.query}}`만이며 `context:ground_truth`를 붙이지 않습니다. 필드 매핑 화면이 나타나면 `query` → `query`를 사용합니다.

관리형 평가자는 정확히 두 개만 남깁니다.

평가기	의미	설정
Relevance	질문에 관련된 답변인지, 1-5점	Threshold 4
TaskAdherence	과제 지시를 따르는지, 이전 0/1 Pass/Fail	통과 1 , 임계값 4가 아님

명시적 Judge 배포를 선택하고 서비스 생성 매핑을 유지합니다. Relevance는 `response={{sample.output_text}}`, TaskAdherence는 `response={{sample.output_items}}`입니다. 이전 UI 값으로 덮어쓰지 말고 정의의 Raw JSON을 확인합니다.

역할	모델·버전	배포
Agent	gpt-6-sol / 2026-09-22	lab-agent-sol-dea3cec5
평가 Judge	gpt-6-luna / 2026-09-22	lab-judge-luna-dea3cec5
Optimizer 생성	gpt-5.5 / 2026-04-24	lab-planner-dea3cec5

Sol의 실제 Agent·도구 호출을 확인했습니다. 카탈로그 표시만으로 충분하지 않으며 [Optimizer 지원 목록](https://learn.microsoft.com/azure/foundry/agents/concepts/agent-optimizer-overview#models) (<https://learn.microsoft.com/azure/foundry/agents/concepts/agent-optimizer-overview#models>)은 별도입니다. 카탈로그 평가기 버전 링크가 비공개 서비스 루브릭 고정 of 증거는 아니므로 실제 정의와 한계를 기록합니다.

Microsoft Foundry / proj-fev11-860db66e

Q Search with AI (Beta)

New Foundry

Home Discover Build Operate Manage Docs

Create

Agents

Models

Services

Tools

Knowledge

Memory

Guardrails

Data

Optimize

Evaluations

Fine-tune

← Create new evaluation

Target: Agent

Scope

Frequency

Data

Configure agents

Criteria

Review

Choose what criteria you want to evaluate — quality, risk and safety, and more.

Judge model *

Model: lab-judge-860db66e

We've auto-suggested the following 2 evaluators

Agents (1)

TaskAdherence

Quality (1)

Relevance

Add new evaluator

Back

Next

Mapped fields from your dataset:

query: {{item.query}}

response: {{sample.output_text}}

context: {{item.context}}

ground_truth: {{item.ground_truth}}

tool_calls: {{sample.tool_calls}}

tool_definitions: {{sample.tool_definitions}}

Instructions

What evaluators are not auto-selected here?

Evaluators from Azure OpenAI come with text-based field mappings to give you more flexibility beyond one to one mapping. You will need to specify field relationship when you construct your system, user and assistant prompts. Don't worry, we have templates so you won't have to start from scratch.

두 평가기와 Judge를 구분합니다. 한국어 프로젝트의 미제출 설정에서 Relevance 4·TaskAdherence 1을 각각 확인했습니다. 화면의 이전 Judge 배포를 현재 Luna 배포로 오인하지 말고 자신의 운영자 인수 정보를 사용합니다. 원본 크기로 보기 (파일: web/assets/portal/16-evaluation-criteria.png)

완료 신호: 두 평가기 척도·임계값·매핑·실제 Judge를 기록했습니다. 오래된 로컬 환경 기본값이 아니라 저장된 원격 정의가 Judge를 결정합니다.

03. Foundry Evaluation 실행

v1 + 원본 dev12 + query 전용 입력 + 두 평가기 + Luna Judge를 검토합니다. 현재 영어 비교는 contoso-en-sol-learning-loop입니다. 기록된 리허설을 살펴보는 경우 기존 완료 run을 열고 다시 제출하지 않습니다.

새 승인 수업은 **Review → Submit**으로 한 번 제출하고 실제 evaluation ID·run ID를 기록합니다. 완료를 기다리고 오류·누락까지 전체 12건을 확인합니다. 초안 구성·HTTP 생성 응답·모델 연결 확인이 평가 완료를 뜻하지 않습니다.

Microsoft Foundry / proj-fev11-860db66e

Search with AI (벡K)

New Foundry Home Discover Build Operate Manage Docs

Create

Agents

Models

Services

Tools

Knowledge

Memory

Guardrails

Data

Optimize

Evaluations

Fine-tune

Create new evaluation

Target: Agent

Scope

Frequency

Data

Configure agents

Criteria

Review

Add a name and description to this evaluation run.

Evaluation name *

contoso-ko-ui-preview-not-submitted

Back Submit

Summary

Agent evaluation

Targets

lab-20260930-live-iq

Agent Edit

Scope

Individual turns

Scope Edit

Frequency

One time

Frequency Edit

Dataset

contoso-dev-v11-860db66e

Version 1

Existing dataset Edit

Evaluators

TaskAdherence

Agents Edit

Relevance

Quality Edit

Submit 전 검토 위치. 기존 한국어 Agent와 한국어 데이터셋을 선택한 촬영용 미제출 설정입니다. 자신의 고정 버전·평가 계약을 확인하며, 이 화면을 평가 완료나 현재 Sol 실행의 증거로 사용하지 않습니다. 원본 크기로 보기 (파일: [web/assets/portal/17-evaluation-review.png](#))

완료 신호: 실제 Foundry run이 Completed이고 결과 12건을 확인할 수 있습니다. 실패·부분 실행을 그대로 기록하며 관리형 Evaluation을 자체 로컬 Judge로 대신하지 않습니다.

04. 점수와 이유 읽기

요약과 **Detailed metrics result**의 Relevance.reason, TaskAdherence.reason을 읽습니다. conversation_id → User view는 실제 질문·응답이며 인라인 Judge 이유 패널이 아닙니다.

실패 또는 최저점 사례와 잘한 사례를 골라 **질문 → 실제 응답 → 점수·이유 → 정책·참고 답변**을 연결합니다. 실패가 없으면 그 사실을 말하며 사례를 만들려고 기준선을 약화하지 않습니다.

Microsoft Foundry / proj-fev11-860db66e

Search with AI (3K)

New Foundry

Home

Discover

Build

Operate

Manage

Docs

Create

Agents

Models

Services

Tools

Knowledge

Memory

Guardrails

Data

Optimize

Evaluations

Fine-tune

candidate_1

Make recurringDelete

Run details

Status

Completed

Create time

9/30/2026, 10:25:16 AM

Duration

9m 52.83s

Created by

-

Agent ID

lab-20260930-live-ig:draft-1790731431077

See all properties

Raw JSON

User logs

Download user logs

Results

Download results

Overall metric results

P50 latency

50.9s

P95 latency

63.0s

relevance

100%
12 / 12

Task adherence

67%
8 / 12

Detailed metrics result

Analyze Results

Index	query	conversation_id	trace_id	relevance
0	다음 달 비용이 부담됩니다. 구독을 내려주세요. 아예 안 쓸지 낮은 등급으로 계...	conv_07d840854d53f37b007nkrtdbSJ3qpGzt1YCDngGIuTc7humo	-	Pass: 4
1	최초 월 결제는 2026년 8월 28일 08:00 KST입니다. 미사용 상태이고 9월 6일 ...	conv_050016fea2c751c0007prjsZ8XQfyryrkp9S5msY6SqXyoeJSj	-	Pass: 4
2	2026년 9월 8일 첫 월 결제 후 하루만 이용했습니다. 유료 크레딧 사용량은 0이...	conv_032c635f95c5bb7700ulHleLkvzxHzeV5ynfdyQng2dCRLCoS	-	Pass: 4
3	지원 > 문의 화면에서 제목만 쓰다가 나왔고 제출 버튼은 누르지 않았습니다. 이 ...	conv_0eb912e020275e9790y74rr8rMdYSIEBelanD1KYtgEMHBK084	-	Pass: 4
4	관리자 감사 화면에 처음 보는 접근 이벤트가 있습니다. 제가 한 일은 아닌 듯하지...	conv_08485eb422673787002GVueju2TbKhd5z6f31qwwuCTvcZt9hF	-	Pass: 4
5	동일한 월 기본료를 낸 두 달의 인정 가용성이 각각 94%와 100%라고 가정합니...	conv_081caec23c81df6600BXrWDjrevHRD9RR8ypsQt27UTgHQti	-	Pass: 4
6	유료 Pro인데 헬스 배타 전달만 실패했고 프로덕션 API 자체는 정상입니다. 같은 ...	conv_0697cde7065c7fd00iCjE4jq9URnDAK8BZc3vgpYEXSg97IEZ	-	Pass: 4
7	월 99.9% 약정이 있으니 자동 다중 리전 장애조치가 내장됐다고 제안서에 써도 ...	conv_0894fa3e02c74d9200BuCA0rN9uda4gkwBh9YgXi6K74m02bKS	-	Pass: 4
8	환불은 결제 후 마지막 시각을 포함한다고 배웠습니다. 1% 환불만 승인된 부분과 사...	conv_0e5fd33fa4c7244d00MosPbxV7N79rCMAMu6F6a6S7aBXNl	-	Pass: 4

한국어 질문과 점수 위치. 이전 한국어 Optimizer 후보의 관리형 평가 화면입니다. 현재 Sol 실행이나 영어 실측을 나타내지 않습니다. 현재 run ID와 전체 사례는 최신 보고서를 기준으로 읽습니다. 원본 크기로 보기 (파일: web/assets/portal/11-evaluation-results.png)

Relevance 4/5를 정확도 80%로 해석하지 않습니다. TaskAdherence 1은 통과이지 낮은 5점 척도 점수가 아닙니다. 누락은 0점이나 성공 행이 아니며 범용 평가기가 모든 업무 규칙을 인증하지는 않습니다.

conv_07d840854d53f37b... Conversation ID: conv_07d840854d53f37...

Trajectories User view Graph view

5 spans 1 chat call 1 tool call 42.4s 16.9Kt 1 error

다음 달 비용이 부담됩니다. 구독을 내려 주세요. 아예 안 쓸지 낮은 등급으로 계속 쓸지는 아직 말을 안 드렸네요.

다음 달 비용이 부담됩니다. 구독을 내려 주세요. 아예 안 쓸지 낮은 등급으로 계속 쓸지는 아직 말을 안 드렸네요.

```
{  "answer": "Contoso Atlas Cloud 구독 변경 또는 취소는 다음 달 구독 시작일 기준으로 처리됩니다. 구독 변경 신청은 월간 청구 기준으로 매월 1일 00시부터 10시(KST) 사이에 접수되어야 하며, 그 이후 신청은 다음 달부터 적용됩니다. 구독을 낮은 등급으로 변경하거나 취소하려면 프로필 내 '설정 > 결제 > 자동 신청'에서 직접 변경하실 수 있습니다. 구독 취소 시 서비스는 중단되며 사용 권한이 바로 없어집니다. 구체적인 변경 절차나 일정은 계정 내 결제 설정에서 확인하시기 바랍니다.",  "citations": ["ATLAS-SUB-001"],  "route": "answer",  "needs_human": false}
```

한국어 응답도 정책과 대조합니다. 이전 완료 실행의 실제 응답이며 정답 예시가 아닙니다. 화면의 오류 표시와 잘못된 정책 설명을 그대로 보존했습니다. 채점 이유는 Detailed metrics result로 돌아가 읽으며 현재 Sol 결과로 복사하지 않습니다. 원본 크기로 보기 (파일: web/assets/portal/19-evaluation-case.png)

날짜 경계 오류, 불필요한 가정, 정책 ID 대신 숫자 검색 ID, 사람 검토 분류 오류, 실행 완료 주장과 근거 없는 확신을 확인합니다. 정직한 불확실성을 높은 점수를 위한 허위 사실로 바꾸지 않습니다.

공유: 실제 run ID·지표별 척도·통과 건수와 문제 응답을 제시하고 어떤 지침 행동을 개선할지 설명합니다.

완료 신호: 평균만이 아니라 실제 약점과 근거 있는 개선 가설을 설명할 수 있습니다.

05. Agent Optimizer로 지침 개선

Build → Agents → 준비된 언어별 Agent → Optimize Preview → Agent를 엽니다. Cost가 아닙니다. 영어 대상은 `contoso-eval-en-sol`이며 새 작업에서는 **Create an optimization run**을 사용합니다.

설정	선택
Agent version	명시적 기준선 1
Choose targets	Instruction only , Model·Tool description �기
Max candidates	운영자 승인 한도. 이번 작업은 최대 2이며 정식 버전 수와 다름
Optimization model	<code>lab-planner-dea3cec5</code> / gpt-5.5
Evaluation model	<code>lab-judge-luna-dea3cec5</code> / gpt-6-luna
Dataset	같은 언어의 등록 dev12·같은 버전
Criteria	Relevance 4, TaskAdherence 이진 통과 1

Create an optimization run

1Target

Optimization tunes your agent's instructions and tool descriptions. Optimization can also tune your agent's quality by attempting different models. To also compare models, turn on Compare across models and pick which ones to include.

Goal
Improve quality
Raise evaluation quality above your current version, with token cost left free.

Agent

lab-20260930-live-iq

Version

v1 (latest)

Optimization approach

☐ Auto

Foundry chooses which eligible attributes to optimize based on the available budget.

☒ Choose targets

Choose the attributes Foundry should attempt to optimize within the available budget. Targets that do not apply to your agent are skipped.

☒ Instruction

☐ Tool description

☐ Model

Optimization model

lab-planner-860db66e

Max candidates

1

Evaluation model

lab-judge-860db66e

Next

2Data

3Review



How optimization works

Scored and ranked
Each candidate is scored against your criteria and ranked by performance.

Verify before applying
Review the top candidate before applying changes to your agent.

Criteria가 **No custom evaluators available**이면 **Custom only OFF** 또는 **View built-in evaluators**를 선택합니다.
 각 기본 평가기의 임계값을 설정하고 Apply합니다. 필터를 우회하려고 다른 평가기를 만들지 않습니다.

Create an optimization run

Target

Dataset

Criteria

Review

Select dataset

Search by file name

Create dataset from traces

Upload dataset

Name	Version	Created by	Created on
☐ eval-data-2026-09-30_012516_4b0ec_UTC	1		9/30/26, 10:25:17 AM
☐ eval-data-2026-09-30_012352_64ea8_UTC	1		9/30/26, 10:23:52 AM
☐ eval-data-2026-09-30_012156_e535e_UTC	1		9/30/26, 10:21:57 AM
☐ eval-data-2026-09-30_012114_fc0b3_UTC	1		9/30/26, 10:21:15 AM
☐ eval-data-2026-09-30_012027_58f39_UTC	1		9/30/26, 10:20:27 AM

1-5 of 8

Prev


Next

한국어 데이터 재사용. 이전 한국어 프로젝트의 선택 전 목록입니다. 화면의 첫 항목을 그대로 고르지 말고 운영자가 지정한 한국어 dev12-같은 등록 버전과 12행 전체를 사용합니다. 데이터를 새로 생성하거나 수정 업로드하면 실험 조건이 달라집니다. 원본 크기로 보기 (파일: `web/assets/portal/08-optimizer-dataset.png`)

승인된 비용 범위에서 한 번 제출하고 최대 60분 기다린 뒤 실제 상태를 남깁니다. 재개 시 기존 job ID를 사용합니다. 작업 하나에도 여러 내부 호출이 포함됩니다.

원본-후보 결과와 **View changes**를 읽습니다. 내부 **0-1 순위**는 별도 관리형 Evaluation 평균-통과율과 다릅니다. 모델-도구-추론-출력 스키마를 유지하며 함수 도구 export가 비었다고 MCP 정책 연결을 제거하지 않습니다.

현재 실행: 관리형 Optimizer는 이미 강한 v1을 유지하도록 선택했습니다. 생성 후보를 자동 승격하지 않았고, 운영자가 관측한 실패를 바탕으로 지침을 정리한 뒤 초안을 별도로 검증했습니다. 따라서 현재 v2는 **Agent Optimizer 이후 운영자가 검토한 지침**이며 서비스가 자동 추천한 후보라고 표시하지 않습니다.



순위뿐 아니라 후보를 확인합니다. 이전 한국어 실습의 결과이며 이 화면의 개선 폭은 현재 Sol 결과가 아닙니다. 현재 보고서에서 실제 작업·후보 ID를 확인합니다. 원본 크기로 보기 (파일: web/assets/portal/09-optimizer-results.png)

Changes: candidate_1 ★ Best candidate

Comparing candidate_1 against baseline configuration.

Baseline

```
1 {
2   "agentName": "lab-20260930-live-iq",
3   "agentVersion": "1",
4   "system_prompt": "Contoso Atlas Cloud의 고객지원 도우미입니다. 제
   공된 고객 문의와 정책 문맥을 참고하여 한국어로 답하세요.\n정책 질문이고
   knowledge_base_retrieve 지식 도구가 연결되어 있으면 답하기 전에 그 도구
   로 근거를 확인하세요. 도구나 문맥이 없으면 정책 내용을 만들어 내지 말고 한계를
   밝히세요.\n응답은 다른 텍스트나 마크다운 없이 다음 네 필드만 가진 JSON 객체
   하나여야 합니다.\n{\n  \"answer\": \"답변 문자열\", \"citations\": [\"문
   서 식별자\"], \"route\": \"answer\", \"needs_human\":
   false\n}\nroute는 answer, clarify, escalate, refuse 중 하나입니다.
   citations는 문자열 배열입니다. needs_human은 route가 escalate일 때만
   true이고 나머지는 false입니다.\n\",
5   \"skills\": [],
6   \"tools\": []
7 }
```

Candidate: candidate_1

```
1 {
2   "agentName": "lab-20260930-live-iq",
3   "agentVersion": "1",
4   "system_prompt": "당신은 Contoso Atlas Cloud의 고객지원 도우미입니
   다. 사용자의 한국어 고객 문의에 대해, 제공된 정책 문맥 및 사용 가능한 지식 도
   구를 근거로 한국어로 답변합니다.\n\n입력 형식:\n- 사용자는 보통 Contoso
   Atlas Cloud의 SLA 크레딧, 환불, 구독/청구, 보상 계산 조건 등에 대해 한국
   어로 질문합니다.\n- 대화에 정책 문맥이 직접 제공될 수 있고,
   'knowledge_base_retrieve' 지식 도구가 연결되어 있을 수 있습니다.\n\n도
   구 사용 원칙:\n1. 사용자의 질문이 정책, SLA, 환불, 보상, 청구, 구독 조건에
   관한 것이라면, 'knowledge_base_retrieve' 도구가 사용 가능할 때 반드시
   최종 답변 전에 도구를 호출하여 근거를 확인하세요.\n2. 도구가 없거나 정책 문맥
   이 없고, 아래 "내장 정책 사실"에도 없는 내용이라면 정책 내용을 만들어 내지 마
   세요. 그 경우 확인 가능한 근거가 부족하다고 밝히고 필요한 정보를 요청하거나 상
   당 원 확인을 안내하세요.\n3. citations에는 실제로 근거로 사용한 문서 식별자만
   넣으세요. 검색 결과나 문맥에서 확인되지 않은 문서 ID를 임의로 넣지 마세
   요.\n4. URL, 각주 표기, [...] 같은 인용 마크업은 답변 문자열에 넣지 마세
   요. citations 배열에 문서 ID만 넣으세요.\n\n최종 응답 형식:\n- 최종 응답
   은 반드시 아래 네 필드만 가진 JSON 객체 하나여야 합니다.\n- 배열로 감싸지 말
   고, 설명 문장이나 마크다운을 JSON 밖에 쓰지 마세요.\n- 필드명과 타입을 정확히
   지키세요.\n\n{\n  \"answer\": \"한국어 답변 문자열\", \"n
   \"citations\": [\"문서 식별자\"], \"route\": \"answer\", \"n
   \"needs_human\": false\n}\n\nroute 규칙:\n- \"answer\": 확인된
   정책 또는 제공된 정보만으로 답변할 수 있을 때. 계산이 불가능하더라도 그 이유와
   필요한 입력을 설명할 수 있으면 보통 answer를 사용합니다.\n- \"clarify\":
   답변을 진행하려면 사용자의 추가 정보가 반드시 필요하고, 현재는 정책적 결론도 내
```

1 of 1 Close

한국어 지침의 실제 차이를 읽습니다. 이전 한국어 후보 예시이지 현재 Sol 지침이 아닙니다. 자신의 현재 후보에서 허위 정책·근거 없는 확산·설정 변경을 거부합니다. 지침이 길다고 더 좋지는 않습니다. 원본 크기로 보기 (파일: web/assets/portal/10-optimizer-changes.png)

v3·v4 등 정식 버전을 계속 만들지 않습니다. 운영자가 후보를 명시적 초안으로 먼저 평가합니다. 같은 기준의 실제 검증에서 품질 회귀 없는 개선을 확인한 뒤에만 **Promote** 또는 **v2 생성**을 진행합니다. 승격은 운영용 게시·운영 트래픽 변경 승인이 아닙니다.

공유: 어떤 지침 행동이 바뀌고 무엇이 개선·회귀할 수 있나요? 이전 그림이 아니라 실제 현재 후보를 제시합니다.

완료 신호: 실제 관리형 Optimizer 결과와 검토 후보가 있으며 별도 재평가가 필요함을 이해했습니다.

06. 재평가·v1/v2 비교

같은 **Foundry 평가 정의**, 같은 dev12·Luna Judge를 사용합니다. 이 포털의 Add run에서는 Unable to create data source configuration from item schema가 관측됐습니다. 공식 Azure AI Projects/OpenAI Evals helper로 실제 관리형 run을 제출하며 로컬 채점이 아닙니다.

운영자가 준비한 venv와 검증된 az login 상태에서 다음 네 자리표시자를 **자신의** 프로젝트·기준선 ID로 교체합니다. 한국어 실습에는 별도의 한국어 기준선이 필요합니다.

```
export AZURE_AI_PROJECT_ENDPOINT="OPERATOR_PROJECT_ENDPOINT"
export AZURE_SUBSCRIPTION_ID="OPERATOR_SUBSCRIPTION_ID"
export FOUNDRY_EVALUATION_ID="YOUR_EVALUATION_ID"
export FOUNDRY_BASELINE_RUN_ID="YOUR_BASELINE_RUN_ID"
```

운영자는 v2 생성 전에 명시적 초안을 검증할 수 있습니다. 정식 v2가 생성된 뒤에는 다음 명령을 사용합니다.

```
python scripts/add_foundry_eval_run.py --endpoint "$AZURE_AI_PROJECT_ENDPOINT" --subscription
"$AZURE_SUBSCRIPTION_ID" --evaluation "$FOUNDRY_EVALUATION_ID" --baseline "$FOUNDRY_BASELINE_RUN_ID" -
-version 2 --name candidate-v2 --out .lab/foundry-evaluations/candidate-v2.json
```

receipt는 중복 제출을 방지합니다. 동일 명령·경로는 같은 run을 수집할 때만 재사용합니다. helper는 같은 원격 이름, 원격 임계값·Judge·매핑과 모든 결과 행의 실제 버전·시스템 지시도 확인합니다.

Evaluation runs에서 두 행을 선택하고 **Compare runs**를 엽니다. **Baseline**을 **v1**으로 명시 선택하며 행 선택 순서 때문에 비교 방향이 바뀌지 않게 합니다.

Microsoft Foundry / proj-fev11-860db66e

Search with AI (🔍)

New Foundry

Home

Discover

Build

Operate

Manage

Docs

Create

Agents

Models

Services

Tools

Knowledge

Memory

Guardrails

Data

Optimize

Evaluations

Fine-tune

← Statistically compare results

Total runs selected2Analysis methodTTest

Baseline * baseline

Name	baseline	candidate_1
relevance	4.08 Baseline	4.00 Inconclusive
task_adherence	0.58 Baseline	0.67 Inconclusive

1-2 of 2

PrevNext

비교 방향과 결과를 함께 확인합니다. 이전 한국어 Optimizer의 완료 run 두 개를 관리형 평가에서 비교한 화면입니다. 표시된 TTest·평균·Inconclusive는 현재 Sol 비교와 별개입니다. 자신의 정확한 기준선·후보 ID를 사용하여 이 화면을 새 재평가 완료로 해석하지 않습니다. 원본 크기로 보기 (파일: web/assets/portal/20-evaluation-comparison.png)

현재 [v2 검증](#)은 v1 대조군과 12건 전체의 응답·점수·이유를 공개합니다. 전체 기준 통과와 각 지표의 통과 건수·평균이 낮아지지 않고 하나 이상이 명확히 개선되어야 합니다. 사실·분류·응답 형식도 확인하며 지연·토큰·통계 검정은 구분해 보고합니다.

결과 설명: 실제 개선, 같은 평가 기준, 회귀와 남은 불확실성을 설명합니다. 관측된 개선이 향후 모든 확률적 실행의 개선을 보장하지는 않습니다.

완료 신호: 최신 v2의 동일 모델 비교가 완전하고 정직하게 기록됐습니다. 정식 버전을 누적하지 않고 현재 보고서 하나를 유지합니다. 운영 승인·독립적 일반화는 별개이며 dev12 실습으로 부여되지 않습니다.

중요: 실제 run/job ID, 데이터 해시와 실측 결정을 운영자에게 전달합니다. 원본 receipt는 로컬에 보존하고 합성 응답·이유는 인증·쿠키·서명된 URL·비공개 계정 정보 없이 공개합니다. [강사 복구 안내](#) · [데이터 계약](#).

강사 안내 · 실제 측정 결과 개선하기

[참가자 6단계](#) · [운영자 인수](#) · [최신 v2 검증](#)

자사 업무 과제와 실제 관리형 평가로 **평가 → 학습 → 개선 → 재평가**를 설명합니다. 약한 기준선을 인위적으로 만들거나 앞으로의 모든 평가가 개선된다고 약속하지 않습니다.

수업 전

운영자가 `contoso-eval-en-sol`, Sol 모델 배포, 기존 읽기 전용 정책 도구, 등록된 영어 dev12, Luna Judge와 지원되는 `gpt-5.5 Optimizer` 배포를 제공합니다. [운영자 가이드](#)에서 모델 역할·신원을 확인합니다.

v1·v2는 변경 불가능한 Agent 전체 구성 버전입니다. 모델·도구·추론·엄격한 출력 스키마는 같고 지침만 다릅니다. v1부터 근거·분류·날짜·불확실성 지침을 갖추며, 후보 개발은 정식 버전을 계속 늘리는 대신 초안으로 진행합니다.

영어·한국어 데이터와 Agent를 분리합니다. 한국어 가이드는 절차를 설명하며 현재 공개된 실측은 **영어 데이터 결과**입니다.

참가자 단계는 정확히 여섯 개

단계	필수 동작	완료 근거
01 데이터셋	변경 없는 세 열 JSONL과 기존 등록 확인	12행 전체, 버전·SHA-256
02 평가기	Relevance 1–5점·임계값 4, TaskAdherence 이진 0/1·통과 1, Luna Judge	저장된 원격 정의와 query 전용 입력
03 기준선	고정 Sol v1에 실제 Foundry Evaluation	완료된 run ID와 전체 결과
04 분석	실제 답변·점수·이유·정책 읽기	실패를 포함한 구체적인 개선 가설
05 최적화	실제 instruction-only Agent Optimizer와 지침 diff	실제 job/candidate ID, 지침 외 설정 불변
06 재평가	같은 정의·데이터·Judge로 명시적 후보 실행, Compare runs	행별 대응 근거, 개선 검사와 정직한 판단

Individual turns / One time / Existing dataset을 사용합니다. 업로드 미리 보기가 5행이어도 실험은 12행입니다. 버전 선택으로 체크박스가 해제되면 다시 선택하고 대상 한 개를 확인합니다.

실제 사례로 토론

질문 → 실제 답변 → 평가 점수·이유 → 정책·참고 답변을 연결합니다. conversation_id → User view는 대화이며 평가 이유는 Detailed metrics result의 Relevance.reason·TaskAdherence.reason에서 확인합니다.

약한 사례와 강한 사례를 하나 이상 토론합니다. 실패가 없다면 최저점 사례를 사용하며 실패를 관측하지 못했다고 말합니다. v1을 약화하거나 어려운 행·참고 답변을 바꾸거나 로컬 점수로 대신하지 않습니다.

최신 공개 기록은 합성 질문 12건, 두 실제 응답과 관리형 평가 이유를 포함합니다. 평가 결과는 자격 증명이 아닙니다. 제외할 것은 토큰·쿠키·서명된 URL·비공개 계정 정보이지 실패 결과가 아닙니다.

개선 해석

Relevance 4/5는 정확도 80%가 아닙니다. TaskAdherence 1은 통과이지 5점 중 1점이 아닙니다. 지표별 점수·통과 건수, 전체 기준 통과, 오류·평가 범위를 구분합니다.

scripts/compare_foundry_eval.py는 전체 사례 대응, 데이터·모델·도구·설정 일치, 실제 행별 버전·지침, 통과 건수·평균의 비회귀와 하나 이상의 명확한 관측 개선을 요구합니다. 잘못된 JSON을 고쳐 통과로 바꾸지 않고 실패로 남깁니다.

범용 평가기가 통과시켜도 근거 없는 확신, 정책 계산 오류, 실행 완료 주장과 잘못된 분류를 직접 읽습니다. 불가능한 확답을 요구한다고 사실을 만들어내면 안 됩니다.

Optimizer 내부 순위는 후보 선택 근거이지 별도 관리형 재평가의 평균·통과율과 같은 값이 아닙니다. 순위 상승만으로 더 나은 v2가 입증되지 않습니다.

실험 조건을 바꾸지 않는 복구

증상	대응
다른 신원, 401/403	승인된 계정·프로젝트 확인, 공유 권한 확대 금지
카탈로그·배포 성공 후 Agent 실패	실제 API·런타임 오류를 남기고 해당 역할 확인
포털 Add run item-schema 오류	기존 기준선 data source의 공식 SDK helper 사용, 다른 채점기로 대체 금지
No custom evaluators available	Custom only OFF 또는 View built-in evaluators
로컬 receipt·같은 이름의 원격 run 존재	같은 run 재조회, 이름 변경을 통한 중복 제출 금지
후보가 모델·도구·추론·스키마 변경	지침만의 비교라고 주장하지 않음

증상	대응
초안 요청이 정식 번호로 생성	기대한 초안 지원이 아니므로 중단
기존 v2와 소스 불일치	덮어쓰기·v3 생성 금지, 원본 보존 후 확인
결과·점수 누락	부분 실행으로 표시하고 분모를 줄이지 않음
통계 비교 Inconclusive	그대로 보고하며 유의성·동등성을 주장하지 않음

Relevance는 `{{sample.output_text}}`, TaskAdherence는 `{{sample.output_items}}`를 사용합니다. 서비스 생성 매핑을 덮어쓰거나 `ground_truth`를 Agent에 주입하지 않습니다. 오래된 로컬 기본값보다 원격 평가의 실제 Judge가 우선입니다.

흔한 오해 바로잡기

주장	설명
"v2는 지침 파일 번호일 뿐이다."	Agent 전체 버전이며 이번에는 지침만 바꿈
"새 모델 v2를 옛 모델 v1과 비교하면 된다."	지침 효과를 비교하려면 두 버전의 모델이 같아야 함
"실행 전에 반드시 개선된다고 보장한다."	실측 개선은 확인할 수 있지만 향후 확률적 결과는 보장할 수 없음
"성공한 행만 남긴다."	실패·오류·누락까지 전체 사례를 남김
"스키마가 올바른 업무 판단을 인증한다."	구조를 제한할 뿐 정책 사실·분류까지 보장하지 않음
"공개 근거에 쿠키·원본 로그가 필요하다."	합성 실응답·이유를 허용 필드로 공개하고 인증 정보는 제외

현재 보고서 하나로 마무리

오래된 버전별 보고서를 누적하는 대신 **최신 v2 검증과 고정 v1 대조군**을 공개합니다. 과거 원본 receipt는 감사용으로 보존하며 최신 쌍의 결과로 바꾸어 표시하지 않습니다.

동일 모델 비교 결과, 서비스 통계 검정, 자연·토큰 상충 관계와 합성 dev 재사용의 한계를 보고합니다. 후보 활성화는 운영자의 별도 결정이며 운영용 게시를 이번 실습에 포함하지 않습니다.

운영자 사전 준비 · 고정된 Sol v1/v2 비교

[참가자 가이드](#) · [강사 안내](#) · [최신 v2 검증](#)

환경은 수업 전에 준비합니다. 참가자 실습은 데이터셋 → 평가기 → Foundry Evaluation → 사례 분석 → Agent Optimizer → 재평가이며 인프라 구축은 추가 필수 실습이 아닙니다.

기존 격리 프로젝트 사용

운영자가 소유한 North Central US 프로젝트, 기존 정책 연결과 승인된 합성 Contoso 데이터를 사용합니다. CLI·SDK·포털의 계정·테넌트·구독을 각각 확인합니다. 다른 신원이 로그인됐다고 자원을 재생성하거나 운영 트래픽을 사용하거나 공유 권한을 확대하지 않습니다.

영어 대상은 `contoso-eval-en-sol`입니다. 영어·한국어 원본 데이터는 분리하며 한국어 가이드가 새로운 한국어 서비스 실행을 입증하지는 않습니다.

Microsoft Foundry / proj-fev11-860db66e

Q Search with AI (벡K)

New Foundry

Home Discover Build Operate Manage Docs

Use a model

Manage your existing endpoints or deploy a new model.

View deployments

Build an agent

Create an AI agent by configuring instructions, tools, and knowledge without writing code.

Start building

Code an agent

Define and deploy an agent in code using Microsoft Agent Framework for full control and customization.

Start coding

API key

Project endpoint

Azure OpenAI endpoint

Model selection

Test in playground

Run prompts and see responses.

Explore models

Browse available models.

Compare models

Review benchmarks and capabilities.

claude-fable-5-1

Anthropic

gpt-6-astra

OpenAI

MAI-Image-2.6

Microsoft

DeepSeek-V4-Flash

DeepSeek

Recent work

All Agents Models

Name	Version	Type	Last viewed	Endpoint
lab-sft-860db66e	lab-sft-860db66e	Model	9/30/26, 11:03:19 AM	View endpoint

Terms Privacy

한국어 실습 프로젝트 위치 예시입니다. 이전 프로젝트 홈이며 리소스 그룹 화면이나 현재 v2 결과가 아닙니다. 메뉴는 원래 영문입니다. 실제 프로젝트·리소스 그룹·현재 상태는 운영자 인수 정보로 확인합니다. 원본 크기로 보기 (파일: `web/assets/portal/01-project-overview.png`)

세 모델 역할 확인

역할	실제 배포	모델·버전
Agent	lab-agent-sol-dea3cec5	gpt-6-sol / 2026-09-22
관리형 평가 Judge	lab-judge-luna-dea3cec5	gpt-6-luna / 2026-09-22
Agent Optimizer 지시 생성	lab-planner-dea3cec5	gpt-5.5 / 2026-04-24

Sol은 카탈로그 표시뿐 아니라 고정된 Foundry 프롬프트 Agent 호출과 knowledge_base_retrieve 성공으로 확인했습니다. 응답은 네 필드 JSON 계약을 사용했습니다. 두 버전의 모델·읽기 전용 도구·추론 설정·구조화 출력 스키마를 동일하게 유지합니다.

Optimizer는 별도 역할이며 [지원 모델 목록 \(https://learn.microsoft.com/azure/foundry/agents/concepts/agent-optimizer-overview#models\)](https://learn.microsoft.com/azure/foundry/agents/concepts/agent-optimizer-overview#models)을 따릅니다. Agent나 Judge로 동작한다고 최적화 생성 모델로도 지원된다고 가정하지 않습니다.

Microsoft Foundry / proj-fev11-860db66e

Search with AI (꺆K)

New Foundry

Create

Agents

Models

Services

Tools

Knowledge

Memory

Guardrails

Data

Optimize

Evaluations

Fine-tune

Models

DeploymentsModelsPreviewBatch jobs

Serverless deploymentsManaged compute deployments

SearchPTU CalculatorDeploy

Name	Model	Version	Deployment status	Deployment type	Created on ↓	Created by
lab-sft-860db66e	gpt-4.1-mini-2025...	1	Succeeded	Standard	9/30/26, 11:03:19 ...	
lab-embedding-860db66e	text-embedding-3...	1	Succeeded	Global Standard	9/30/26, 8:30:13 AM	
lab-planner-860db66e	gpt-5.5	2026-04-24	Succeeded	Global Standard	9/30/26, 8:30:12 AM	
lab-judge-860db66e	gpt-5.4-mini	2026-03-17	Succeeded	Global Standard	9/30/26, 8:30:11 AM	
lab-agent-860db66e	gpt-4.1-mini	2025-04-14	Succeeded	Standard	9/30/26, 8:30:09 AM	

1-5 of 5PrevNext

모델·버전 열의 위치 예시입니다. 한국어 실습의 Sol 배포 이전 캡처이므로 현재 역할 표와 기록된 API 관측을 사용합니다. 이전 화면을 런타임 성공 근거로 사용하지 않습니다. 원본 크기로 보기 (파일: web/assets/portal/02-model-deployments.png)

충분히 강한 v1과 통제된 v2 준비

영어 기준선은 prompts/en/baseline.txt입니다. 정책 근거, 날짜, 분류, 불확실성과 실행 경계를 포함합니다. 개선을 크게 보이게 하려고 v1을 약화하지 않습니다.

v1·v2는 지침 파일 번호가 아니라 Foundry Agent 전체 구성의 버전입니다. 이번 비교에서는 지침만 다릅니다. 모델·도구·추론·출력 스키마가 달라지면 같은 조건의 실험을 새로 구성해야 하며 이전 모델 점수를 재사용하지 않습니다.

정식 버전은 변경할 수 없습니다. lab/agents.py의 ensure_fixed_release는 **1·2만 허용**하고 같은 구성의 기존 버전을 재사용하며, 다른 구성을 덮어쓰거나 v3를 조용히 만들지 않습니다. 개발에는 명시적으로 고정된 draft-...를 사용합니다. 이번 구독에서 초안 지원을 확인했지만 다른 구독은 초안 요청이 정식 버전으로 처리될 수 있으므로 별도 확인이 필요합니다.

native_response_format()은 공통 응답 스키마를 엄격한 생성 스키마의 지원 범위로 변환합니다. 인용 중복과 needs_human.route 일관성은 생성 후에도 확인합니다. 유효한 JSON 형식만으로 정책 정확성이 보장되지는 않습니다.

등록된 영어 contoso-eval-en-dev12 **버전 1**, data/en/optimizer/dev.jsonl의 12행과 원본 SHA-256을 유지합니다. Agent 입력은 query**만**이며 참고 열을 생성 입력으로 주입하지 않습니다.

Python 3.11–3.14, Azure CLI, 저장소 코드와 requirements.lock을 준비합니다. 다른 사용자의 환경 대신 별도로 준비한 실습 환경을 사용합니다.

```
source .venv/bin/activate
python -m pip install -r requirements.lock
az login
az account show --query "{user:user.name,tenant:tenantId,subscription:id}" -o json
```

출력 값을 승인된 프로젝트와 대조합니다. 운영자는 endpoint·구독·현재 evaluation ID·완료된 기준선 run ID를 제공합니다. 과거 리허설 ID를 복사하거나 Optimizer job ID를 evaluation ID로 사용하지 않습니다.

재평가 helper는 기준선 data source를 복사하고 **원격** 평가 계약을 검증합니다. 오래된 로컬 JUDGE_DEPLOYMENT로 실제 평가 정의의 Judge를 바꾸면 안 됩니다.

비교 조건과 비용 범위 고정

항목	고정 조건
데이터	같은 영어 dev12 바이트·등록·버전·질문·참고 답변
Relevance	관리형 builtin.relevance, 1–5점, 임계값 4
TaskAdherence	관리형 builtin.task_adherence, 이진 0/1, 통과 1
Judge	두 평가기 정의에 같은 명시적 Luna 배포
Agent	같은 Sol 모델·버전, 도구, 추론, 엄격한 출력 스키마
변경 대상	지침만 변경, 정식 버전은 v1/v2
Optimizer	Instruction만 선택, 모델·도구 설명 변경 끄기, 후보 수 제한

항목	고정 조건
공개 보고	최신 v2·고정 v1 대조군과 12건 전체의 민감정보 제거 결과

카탈로그 평가기 버전은 비공개 서비스 루브릭이 완전히 고정됐다는 증거가 아닙니다. 실제 정의·설정과 이 한계를 남깁니다. 재사용 dev12의 개선은 향후 점수·독립적 일반화·운영 승인을 보장하지 않습니다.

최소 권한 확인

현재 Foundry RBAC 안내 (<https://learn.microsoft.com/azure/foundry/concepts/rbac-foundry>)에 따라 승인된 프로젝트 작업만 허용합니다. 역할 할당 권한과 모델·평가 사용 권한은 별개입니다.

정책 도구는 읽기 전용으로 유지합니다. 편의를 위해 구독 Owner를 부여하거나 네트워크 제한·조직 정책을 해제하거나 사용자 간 토큰을 옮기지 않습니다.

비용과 운영 경계

평가는 Agent·Judge를 호출하고 최적화에는 추가 내부 호출이 있습니다. 할당량은 무료 사용량이 아니고 GlobalStandard는 NCUS 내 처리 보장이 아닙니다. 관측 토큰과 실제 청구액을 구분하며 미확인 비용을 0원으로 표시하지 않습니다.

비용·정리 담당자를 지정합니다. Optimizer 순위 상승만으로 운영용 게시나 후보 활성화를 하지 않습니다. 실측 결정과 승인된 운영 검토가 없다면 원본을 유지합니다. 브라우저를 닫아도 과금은 멈추지 않습니다.

현재 비교 쌍 인수

현재 Agent·버전 ID, 역할별 배포, dev12 해시, 평가 설정, SDK 환경, 승인 범위와 [최신 검증 기록](#)을 전달합니다. 영문 보고서는 모든 사례의 실제 응답·점수·채점 이유를 공개합니다.

원본 서비스 파일에는 계정 메타데이터·토큰·서명된 URL이 포함될 수 있어 로컬에서 보관합니다. **합성 평가 결과 자체가 비밀인 것은 아닙니다.** 성공·실패를 모두 포함한 허용 필드만 공개하고, 불리한 결과가 아니라 자격 증명을 제외합니다. 과거 시도는 원본 감사 기록으로 보존하되 현재 버전 보고서에 계속 누적하지 않습니다.

최신 v2 검증·gpt-6-sol

같은 모델의 v1보다 v2 평가 품질이 실제 개선됐습니다. 전체 기준 통과 11/12 → 12/12, Relevance 평균 4.8333 → 4.9167, TaskAdherence 12/12 유지입니다. 과거 실험을 나열하지 않고 현재 Sol 비교 쌍만 보고합니다.

중요한 한계: p95 지연은 10.97 → 42.97초로 늘었고 서비스 통계 검정은 Inconclusive입니다. 관측된 품질 개선이 운영 준비·통계적 유의성·향후 모든 실행의 개선을 보장하지는 않습니다.

실제 측정 범위

contoso-eval-en-sol의 두 버전은 같은 gpt-6-sol / 2026-09-22 Agent, 읽기 전용 정책 도구, 추론 설정, 엄격한 JSON 스키마와 등록 데이터셋 contoso-eval-en-dev12 버전 1을 사용했습니다. 지침만 변경했습니다.

data/en/optimizer/dev.jsonl (파일: data/en/optimizer/dev.jsonl)의 12행을 그대로 사용했습니다. Agent에는 query만 전달하고 context·ground_truth는 참고로 유지했습니다. 두 관리형 평가기와 Luna Judge도 같습니다. 모든 결과 행의 실제 버전·시스템 지시를 확인했습니다.

영어 데이터로 실제 실행한 결과이며 한국어 새 실측이 아닙니다. 로컬 테스트·응답 형식 검사는 Microsoft Foundry 관리형 Evaluation을 대신하지 않습니다.

최종 v1/v2 결과

지표	Sol v1 대조군	Sol v2
평가 사례	12	12
전체 기준 통과	11/12	12/12
Relevance 통과, 임계값 4	11/12	12/12
Relevance 평균, 1-5점	4.8333	4.9167
TaskAdherence, 이진 통과 1	12/12	12/12
실행 오류 / 건너뛴 사례	0 / 0	0 / 0
Agent p50 지연	8.03초	9.71초
Agent p95 지연	10.97초	42.97초

지표	Sol v1 대조군	Sol v2
관측 Agent 토큰	46,167	55,858

평가 정의는 eval_40a593c037e44045a47fe5088438afc5입니다.

v1 run은 evalrun_077d41ff8a534b9caee64f9d6c2a339d, 최종 정식 v2 run은 evalrun_6c9e78cfc9de4f1282eb621c6678d8b1입니다. 초안을 v2로 바꾸어 표시한 것이 아니라 실제 정식 **버전 2**의 결과입니다.

이번 실습 비교의 품질 조건은 PASS입니다. 평가기별 통과 건수·평균이 낮아지지 않았고 한 사례가 Relevance 임계값을 넘었습니다. 모든 후보 응답이 JSON·분류·인용 검사를 통과했습니다. 다만 특히 지연 증가 때문에 **운영 승인은 부여하지 않습니다.**

격리된 미게시 실습 Agent의 활성 버전은 **2**로 선택했습니다. 비교용 고정 v1은 유지하며 운영 채널이나 v2 이후의 정식 버전은 만들지 않았습니다.

전체 12건의 근거 공개

evidence/latest.json (파일: evidence/latest.json)의 case_evidence에는 원본 질문·참고 자료, 두 실제 응답 문자열, 각 평가기의 점수·Pass/Fail·이유, 응답 형식 검사와 지연이 12건 모두 포함됩니다. 어려운 사례를 삭제하지 않았습니다.

사례	Relevance v1 → v2	TaskAdherence v1 → v2
01 구독 변경 의도	5 → 5	1 → 1
02 환불 정책 발효일 전환	5 → 5	1 → 1
03 유료 production 작업 제외 조건	5 → 5	1 → 1
04 미제출 고객 문의	5 → 5	1 → 1
05 의심스러운 접근 이벤트	5 → 5	1 → 1
06 월별 SLA 분리 계산	5 → 5	1 → 1
07 베타 기능과 production SLA	5 → 5	1 → 1
08 가용성 목표와 기능 단정	5 → 5	1 → 1
09 포함·미포함 시간 경계	5 → 5	1 → 1
10 무권한 테넌트 삭제	5 → 5	1 → 1
11 미확인 기능의 잘못된 양자택일	3 → 4	1 → 1
12 SLA 계산 입력 누락	5 → 5	1 → 1

11번은 화면을 확인한 척하거나 기능 상태를 꾸미지 않고 개선했습니다. v2는 **두 주장 모두 근거로 확정되지 않는다**는 명시적 판단, 문서 부재와 기능 부재의 구분, 인증된 확인 경로를 제시했습니다.

실제 v2 응답 일부입니다.

Neither conclusion is established. You don't see a GPU model selection menu, but I haven't inspected your screen or the live service.

전체 응답과 수정하지 않은 관리형 평가 이유는 공개 JSON에 있습니다. 근거는 실제 실행 데이터이지 자격 증명이 아닙니다. 토큰·쿠키·서명된 URL·계정 식별자와 원본 대화·도구 payload는 제외합니다.

모델 역할과 지침 출처

역할	모델·버전	경계
Agent	gpt-6-sol / 2026-09-22	실제 Agent·지식 도구 호출 확인, v1/v2 동일
평가 Judge	gpt-6-luna / 2026-09-22	두 실제 관리형 run에 사용
Optimizer 생성	gpt-5.5 / 2026-04-24	별도 역할이며 공식 지원 목록 준수

실제 관리형 Optimizer job은 opt_87805603c0d74b7897f997502aaea080입니다. 지침만 대상으로 최대 두 후보를 생성했으며, 서비스는 생성 후보 대신 **이미 강한 v1 기준선을 유지**하도록 선택했습니다.

현재 v2는 그 작업 이후 **운영자가 검토·정리한 지침**이지 자동 Optimizer 승격으로 꾸민 결과가 아닙니다. 강한 v1을 유지하면서 근거 없는 양자택일에 명확한 사실 판단과 확인 경로를 제시하도록 개선했습니다. 평가 질문·참고 답변·정책 수치·데이터셋 정답 예시를 지침에 내장하지 않았습니다.

소스는 v1 지침 (파일: prompts/en/baseline.txt)과 v2 지침 (파일: prompts/en/optimized.txt)입니다. 후보 개발은 초안을 사용했고 정식 워크숍 Agent는 **1·2 두 버전만** 유지합니다. 기존 버전을 덮어쓰거나 조용히 번호를 계속 올리지 않습니다.

통계·운영 한계

실제 Foundry 비교는 **PairedTTest**를 사용했습니다.

평가기	평균 차이	p-value	서비스 결과
Relevance	+0.08333	0.33880	Inconclusive

평가기	평균 차이	p-value	서비스 결과
TaskAdherence	0	1.00000	Inconclusive

저장된 결과에서 관측 수치는 개선됐지만 표본이 작고 지침 개발에 재사용한 데이터입니다. 독립적 일반화·통계적 유의성·비용 감소·속도 향상을 주장하지 않습니다. 통과율 상승 뒤에 p95·토큰 증가를 숨기지 않으며 미확인 청구액을 0원으로 표시하지 않습니다.

scripts/compare_foundry_eval.py는 전체 사례·동일 조건·품질 건수와 평균의 비회귀·하나 이상의 명확한 개선을 요구합니다. 잘못된 응답도 실패로 보존합니다. **서비스가 반환한 점수의 검증 조건**이며 새로운 로컬 Judge가 아닙니다.

출처와 공개 경계

현재 보고서는 최신 v2와 같은 모델의 v1 대조군만 보여 줍니다. 과거 원본은 로컬 감사용으로 보존하며 Azure·Git 이력을 삭제하거나 결과를 바꾸지 않았습니다.

한국어 실습 촬영 기록 (파일: web/assets/portal/captures.json)과 NOTICE (파일: web/assets/NOTICE.txt)의 포털 이미지는 **조작 위치 예시**이지 현재 SoI 채점 근거가 아닙니다. 포털 메뉴는 영문이지만 질문·지침은 한국어 실습의 원본입니다. 2026-10-01에 누락된 평가 화면 5개를 Playwright Headless로 촬영했으며, 설정은 제출하지 않고 결과는 이전 완료 실행을 열었습니다. 새 평가·최적화·모델 호출 없이 기존 평가 정의 2개와 Optimizer 평가 run 6개가 유지됨을 확인했습니다. 측정에는 현재 run ID와 전체 공개 사례 기록을 사용합니다.

공식 문서: [Agent 평가](https://learn.microsoft.com/azure/foundry/observability/how-to/evaluate-agent) (https://learn.microsoft.com/azure/foundry/observability/how-to/evaluate-agent) · [Agent Optimizer](https://learn.microsoft.com/azure/foundry/agents/quickstarts/quickstart-optimize-prompt-agent) (https://learn.microsoft.com/azure/foundry/agents/quickstarts/quickstart-optimize-prompt-agent) · [최적화 모델 역할](https://learn.microsoft.com/azure/foundry/agents/concepts/agent-optimizer-overview#models) (https://learn.microsoft.com/azure/foundry/agents/concepts/agent-optimizer-overview#models) · [평가기 정의](https://learn.microsoft.com/azure/foundry/concepts/evaluation-evaluators/agent-evaluators) (https://learn.microsoft.com/azure/foundry/concepts/evaluation-evaluators/agent-evaluators).

Contoso 데이터는 합성입니다. 이전 설계 출처는 [보관된 소스 커밋](https://github.com/junwoojeong100/foundry-evaluation-labs-v0.9/tree/93bc07e31373c4cfc278a2dc3757785946404cf2) (https://github.com/junwoojeong100/foundry-evaluation-labs-v0.9/tree/93bc07e31373c4cfc278a2dc3757785946404cf2)으로 남기며 또 다른 현재 검증 기록은 아닙니다.

로컬 산출물 재확인

```
python scripts/build_datasets.py --language en --check
python scripts/build_datasets.py --language ko --check
python scripts/build_guide.py --check
python -m unittest discover -s tests -q
```

이 명령들은 파일·테스트를 검사하며 Azure 평가를 새로 제출하지 않습니다. 최신 JSON은 문서·브라우저·PDF 검사와 서비스 실적을 분리합니다.

합성 한국어 평가 데이터

[데이터셋 단계](#) · [운영자 인수](#) · English data guide (파일: docs/data-guide.html)

비교에는 변경 없는 데이터셋 하나

한국어 절차는 **data/optimizer/dev.jsonl** (파일: data/optimizer/dev.jsonl)의 **JSONL 12행**을 Foundry Evaluation-Agent Optimizer-재평가에 사용합니다. 운영자가 확인한 별도 한국어 등록을 재사용하고 중복 업로드하지 않습니다.

현재 실제 실행-공개한 데이터는 **영어** data/en/optimizer/dev.jsonl, 등록 contoso-eval-en-dev12 **버전 1**입니다. Agent contoso-eval-en-sol의 v1/v2는 같은 gpt-6-sol 모델을 사용합니다. 한국어 원본은 보존하며 이번 영어 측정을 한국어 새 실행으로 표시하지 않습니다.

목적과 한계

Contoso Atlas Cloud의 정책-질문-참고 답변은 합성 자료입니다. 실제 고객 데이터나 Microsoft-Azure-실제 공급자의 약관이 아닙니다.

공개 벤치마크만 보는 대신 **자사 업무와 기준으로 평가**하는 방법을 익힙니다. 정책 낱파 경계, 모호성, 근거 없는 확신과 실행 완료 주장을 대표 사례로 확인합니다. dev 12건은 학습 루프의 예시이지 운영 안전-독립적 일반화의 인증이 아닙니다.

원본 데이터 보존

data/cases.jsonl (파일: data/cases.jsonl)은 100건이며 train 56, validation 12, dev 12, test 20으로 나뉩니다. 이번 워크숍은 dev12만 사용하며 나머지는 추가 필수 실습이 아닙니다.

결과를 보고 쉬운 행만 선택하거나 중복-병합하거나 참고 답변을 바꾸지 않습니다. 정책 문서 8개 (파일: data/knowledge/documents.json)의 ATLAS-* ID와 발효일을 유지합니다. 정책 연결은 운영자 사전 준비이며 참가자가 별도 지식 시스템을 구축하지 않습니다.

업로드-응답 스키마

JSONL 한 행에는 정확히 세 열이 있습니다.

열	형식	용도
query	문자열	Agent에 보내는 유일한 입력
context	문자열	지원되는 평가기와 사례 검토용 정책 참고 자료
ground_truth	JSON 문자열	구조화 참고 답변이며 생성 프롬프트가 아님

미리 채운 `response`는 없습니다. Foundry가 고정 Agent를 호출해 실제 응답을 얻습니다. JSON 배열로 바꾸거나 열 이름을 바꾸거나 참고 자료를 질문에 붙이거나 응답을 미리 만들지 않습니다.

참고 답변과 Agent 응답은 네 키를 사용합니다.

키	계약
answer	비어 있지 않은 한국어 문자열. 영어 실측은 영어 문자열
citations	근거 정책 문서의 중복 없는 고정 ID
route	answer, clarify, escalate, refuse
needs_human	불리언, route가 escalate일 때만 true

응답 스키마 (파일: `schemas/response.schema.json`)는 분류 일관성도 검사합니다. 네이티브 구조화 출력은 JSON 형식을 제한하지만 사실의 정확성을 보장하지는 않습니다. 숫자 검색 참조 ID는 정책 인용 ID가 아닙니다.

Agent는 티켓 제출·구독 변경·크레딧 승인·데이터 삭제를 실제 수행하지 않습니다. `escalate` 분류가 담당자 연락 완료를 뜻하지 않습니다. 확답을 요구해도 근거 없는 사실을 만들 수 없습니다.

한 번 등록하고 같은 버전 선택

Foundry → Build → Evaluations → Create → Agent에서 명시적 기준선 버전과 **Individual turns / One time / Existing dataset**을 선택합니다. 버전 선택으로 체크가 해제되면 대상을 다시 선택합니다.

기존 dev12 등록을 선택합니다. 등록이 없는 새 승인 프로젝트에서만 정확한 언어 파일을 업로드하고 새 데이터셋 버전을 기록합니다. 미리 보기가 5행이어도 실제 파일·평가 범위는 12행입니다.

custom prompt override는 비워 둡니다. 필드 매핑 화면이 나타나면 `query → query`를 사용합니다. 서비스 매핑은 **Relevance** `response={{sample.output_text}}`, **TaskAdherence** `response={{sample.output_items}}`이며 추가 JSONL 열이 아닙니다.

Relevance 1–5점·임계값 4, TaskAdherence 이진 0/1·통과 1과 같은 Luna Judge를 유지합니다. 두 평가기가 모든 참고 열을 쓰거나 모든 업무 규칙을 인종한다고 주장하지 않습니다.

전체 근거 비교

[최신 보고서](#)는 현재 v2와 같은 모델의 고정 v1을 비교하며 합성 질문 12건, 실제 답변, 평가 점수·이유를 공개합니다. 과거 원본은 감사용으로 보존하되 현재 비교에 섞지 않습니다.

helper는 질문·참고 자료와 실제 행별 Agent 버전·지시를 대조합니다. 오류·누락을 성공으로 바꾸거나 분모에서 빼지 않습니다. JSON·분류 검사는 부가 검증이며 **관리형 평가를 대신하는 로컬 Judge가 아닙니다**.

Agent Optimizer 내부 순위와 별도 관리형 실행의 평균·통과율을 구분합니다. 후보 지침을 검토하고 모델·도구·추론·스키마를 유지합니다. 개발은 초안으로 진행하며 정식 워크숍 버전을 v1/v2 이상으로 계속 올리지 않습니다.

공개 근거에서는 인증 정보·서명된 URL·비공개 계정 메타데이터를 제외합니다. 합성 응답과 실패 이유 자체는 공유할 수 있습니다. 성공과 실패 모두 같은 기준으로 공개합니다.